




1 년 만에 빅데이터의 주역이 된 ‘스파크’, 비결은 기계학습

- 6 월 중순 개최된 사용자 컨퍼런스 ‘스파크 서밋 2015(Spark Summit 2015)’는 스파크가 향후 빅데이터 처리에서 핵심 기술이 될 것임을 확인할 수 있었던 자리
 - 2,000 여 명의 사용자들이 모인 이번 컨퍼런스에서는 우버, 에어비앤비, 도요타, 바이두 등의 기업은 물론 미 중앙정보국(CIA)까지 등단하여 스파크의 활용 사례를 발표
 - IBM 은 스파크 기술은 “데이터 분야에서 향후 10 년간 가장 중요한 오픈소스 소프트웨어(OSS)”라고 하면서, 앞으로 3,500 명의 연구자와 개발자를 스파크 관련 프로젝트에 참여시킬 것이라는 계획을 발표
 - 스파크는 수십~수백 대의 PC 서버를 연계하여 빅데이터를 고속으로 처리할 수 있는 분산 데이터 처리 소프트웨어로서, PC 서버의 대수를 늘리는 것만으로 성능을 향상시킬 수 있으므로 고가의 대형 서버 없이 저비용으로 빅데이터를 처리할 수 있음
 - 스파크는 캘리포니아 버클리 대학에서 개발이 시작되었고, 현재는 이 대학 연구원들이 창업한 스타트업 데이터브릭스(Databricks)가 개발을 주도하고 있으며, 정식 버전인 ‘스파크 1.0’이 공개된 것이 불과 1 년 전인 2014 년 5 월의 일
 - 짧은 시간에도 불구하고, 스파크는 빅데이터 처리 소프트웨어의 대명사인 하둡(Hadoop)의 뒤를 잇는 차세대 빅데이터 처리의 주역으로 급부상하게 된 것
- 스파크와 하둡은 분산 데이터 처리 소프트웨어라는 점에서 같지만, 스파크는 하둡이 잘 처리하지 못하는 ‘기계학습’을 고속으로 처리할 수 있다는 것이 차별화된 강점
 - 가령 스파크 서밋에서 세션 강연을 맡은 도요타 USA 는 스파크를 사용함으로써 이전에는 36 시간 걸리던 기계학습의 처리시간을 불과 9 분으로 단축시켰다고 공개
 - 도요타 USA 는 2015 년 4 월 기계학습을 이용하여 트위터 등의 SNS 에서 사용자가 트윗한 댓글을 컴퓨터가 내용에 따라 자동 분류하는 시스템을 개발
 - 즉, 컴퓨터가 빅데이터를 기계학습 함으로써, 사용자들이 SNS 에서 한 발언이 “자동

* 본 내용과 관련된 사항은 산업분석팀(☎ 042-612-8296)과 최신 ICT 동향 컬럼리스트 박종훈 집필위원(soma0722@naver.com ☎ 02-739-6301)에게 문의하시기 바랍니다.

** 본 내용은 필자의 주관적인 의견이며 IITP 의 공식적인 입장이 아님을 밝힙니다.

- 차의 성능”에 관한 것인지, “딜러의 서비스”에 관한 것인지, “도요타 광고”에 관한 것
인지를 판단하는 ‘규칙을’ 자동으로 찾아 낼 수 있으며, 여기에 스파크를 이용한 것
- SNS 상에서 이루어지는 발언은 방대하기 때문에 그 내용을 사람이 검사하는 것은 불가능한 일이며, 사용자의 의견을 자동으로 분류하는 시스템을 구현함으로써 방대한 댓글 중에서 제품 및 서비스 개선으로 이어질 유용한 의견만 추릴 수 있게 된 것
- 스파크가 기계학습을 고속으로 처리 할 수 있는 것은 데이터를 메모리에 저장하는 ‘인 메모리(in-memory)’ 데이터베이스 기술을 이용하기 때문
- 기계학습에서는 컴퓨터가 만든 규칙이 현실의 규칙과 어느 정도 부합하는지 데이터를 바탕으로 통계적 방법에 의해 여러 번 검증함
 - 하둡에서는 이러한 검증 처리 때마다 데이터를 하드디스크 드라이브(HDD)에서 읽거나 데이터를 HDD에 기록하기 때문에 처리 시간이 오래 걸림
 - 이에 비해 스파크는 느린 HDD를 사용하지 않고 필요한 데이터를 메모리에 저장한 상태에서 검증 작업을 실시하기 때문에 하둡에 비해 처리 시간을 단축할 수 있음
 - 이런 장점에 더해 스파크는 하둡과의 공존도 가능한데, 스파크는 하둡의 표준 스토리지인 HDFS에 저장된 데이터에 대해서도 작업을 수행할 수 있기 때문
 - 이로 인해 스파크는 하둡을 대체하는 것이 아니라 보완하는 성격을 띠는 것으로 받아들여졌고, 기존 하둡 사용자들이 스파크를 용이하게 도입할 수 있었기 때문에 불과 1년 만에 급속히 보급이 이루어지는 원동력이 되었다는 분석
- 스파크 서밋 세션에는 데이터브릭스의 CTO가 등단하여 스파크의 사용 현황에 대해 발표했으며, 현재 가장 대규모로 스파크를 이용하는 곳은 중국 기업들
- 중국의 SNS 사업자인 텐센트는 8,000대의 서버에서 스파크를 운용 중이며, 전자상거래 업체인 알리바바 그룹은 스파크를 이용해서 한 번에 1 페타바이트의 데이터를 처리한다고 함
 - 바이두(Baidu) 역시 현재 1,000대 이상의 서버를 이용해서 스파크를 운용 중이



<자료>: Databricks

(그림 1) 스파크 서밋 2015의 데이터브릭스

며, 인터넷 광고와 검색, 지도 서비스, 전자상거래 등 여러 사업 영역에서 스파크를 활용 중

- 세션에 등단한 바이두는 자신들의 기계학습에 있어서 스파크는 필수적인 플랫폼이 되고 있다고 설명
- 바이두는 향후 스파크를 확장함으로써 인간의 뇌를 모델로 한 기계학습 기법인 ‘딥러닝(Deep Learning)’의 처리에도 스파크를 사용하는 방안을 검토 중이라 밝힘

○ 이 밖에도 이번 컨퍼런스에서는 단기간에 큰 성공을 거둔 스타트업들이 스파크의 도입 및 활용사례를 강연

- 에어비앤비는 전세계 여러 도시의 숙박 수요를 1 일 단위로 예측하고 방값을 결정하는 의사결정 지원 시스템을 스파크를 사용해서 개발한 것으로 알려져 있음
- 실제 에어비앤비에서 대여되는 객실 요금은 1 일 단위로 변동하고 있으며, 이 가격은 에어비앤비에서 방의 소유자들에게 제공하는 ‘가격결정 지원 시스템’에 따라 정해짐
- 가격결정지원 시스템은 숙박과 관련한 50 억 건의 데이터를 컴퓨터가 기계학습 후 만들어 낸 예측 모델에 따라 산출된 적절 요금을 방 소유자에게 조언하고 있음
- 우버는 어떤 업무에서 스파크를 사용하는지 언급하지는 않았지만, 여러 사업부문에서 스파크를 이용 중이라 밝히고, 다양한 사업부문이 스파크를 공동으로 활용하는 노하우에 대해 강연

○ 스파크 서밋 행사에서 이채로웠던 것은 CIA 가 참석하여 발표한 사례로, CIA 는 방대한 데이터 속에서 어떤 징후를 빨리 캐치해야 했고, 여기에 스파크가 필요했다고 설명

- CIA 는 현재 200 대의 서버에서 스파크를 운용하고 있다고 하며, 빅데이터 속에서 어떤 징후를 빨리 잡아낼 수 있으려면 데이터 분석 속도가 중요하고, 이를 위해 2014 년부터 스파크를 활용하게 되었다고 함
- 한편, CIA 는 스파크와 같은 OSS 를 적극 활용하고 있다고 밝히면서, 2014 년에는 아마존 웹 서비스(AWS)에 의뢰해서 AWS 의 퍼블릭 클라우드와 동일한 사양의 클라우드 환경을 CIA 의 데이터 센터에 구축했다고 함
- CIA 가 보기에 AWS 의 매력은 OSS 등 다양한 소프트웨어가 이용 가능하다는 것이며, AWS 자체가 OSS 의 생태계를 형성하고 있다는 점으로, AWS 와 같은 에코시스

템을 CIA 의 클라우드 안에도 만들 필요가 있다고 발표

(ZDNet, 6. 17. & inside BIGDATA, 6. 18.)