



의사결정나무 (1) (Decision Tree Induction)

김 종 우

Jong Woo Kim



한양대학교



목차


1. 의사결정나무는 무엇인가?
2. 의사결정나무는 어떻게 생성되나?
3. 순수도 척도 – Gini와 엔트로피
4. 순수도 척도 – Information Gain Ratio와
카이제곱, 연속형 목표변수의 순수도 척도

1. 의사결정나무는 무엇인가?

서론

- 의사결정나무(Decision Tree)
 - 분류와 예측에 자주 쓰이는 강력한 방법
 - 규칙을 쉽게 이해될 수 있는 문장으로 표현
 - SQL과 같은 데이터베이스 접근 언어로도 쉽게 표현
 - 다수의 입력변수 후보들과 목표변수의 관계에 대한 통찰을 얻을 수 있도록 데이터 탐색에 유용
 - 모형 정확도(model accuracy)와 모형 투명도(transparency)간의 trade-off
 - 예) 우편물 발송
 - 예) 보험 계약에서 특정 변수에 의한 계약 거부

의사결정나무 예



통신회사의 고객 이탈 분류를 위한 의사결정나무

의사결정나무는 무엇인가


- 의사결정나무

- 일련의 단순한 의사결정 규칙들을 적용시켜 큰 레코드의 집합을 작은 레코드의 집단으로 나누는 데 쓰이는 구조
- 예) 생물학의 종, 속, 과, 목, 강, 목, 계
- 의사결정나무 모형은 특정한 목표변수에 대하여 큰 다원적인 모집단을 작은 일원적인 집단들로 나누는 규칙들의 집합을 포함


- 의사결정나무를 자동으로 생성하는 알고리즘

분류

- 스무고개(Twenty Questions)
 - 일련의 질문
 - 앞선 질문의 답이 그 다음 질문을 결정
- 의사결정 나무
 - 연속된 질문들
 - 뿌리 노드
 - 자식 노드
 - 말단 노드
 - 특정 분류값을 가짐




이지 의사결정나무




캠페인 응답여부에 대한 의사결정 나무 생성 예

여러 가지 형태로 만들어지는 의사결정나무



캠페인 응답여부에 대한 의사결정 나무 생성 다른 예

점수화(Scoring)




이 의사결정나무는 각 노드별로 클래스 T, F에 속한 레코드의 비율을 표기하고 있으며, 이는 분류 확률로 생각할 수 있다

추정

- 누가 응답할 것인가?
- 고객의 다음 주문량이 얼마일까?
- 회귀나무(Regression tree)
 - 수치형 목표변수
 - 순수도를 증가시키는 대신 목표변수의 값들의 분산을 감소시키도록 나무를 분기
- 의사결정나무를 연속형 값을 추정하는 데 사용하는 것은 그다지 좋은 생각은 아님
 - 회귀모형이나 인공신경망

의사결정나무를 이용한 추정과 인공신경망을 이용한 추정 비교

- 자전거 대여 수요 예측 예



실제 수요(대여대수)

인공신경
망으로
예측한
수요
(대여대수)

SR-cnt

cnt

실제 수요(대여대수)

2. 어떻게 의사결정나무가 생성되나?

어떻게 의사결정나무가 생성되나

- 모든 의사결정나무 알고리즘들은 기본 절차에 있어서는 공통점을 가지고 있음
 - 목표변수 측면에서 부모노드보다 더 순수도(purity)가 높은 자식노드들이 되도록, 데이터를 반복적으로 더 작은 집단으로 나눈다(repeatedly split)

분기의 발견

- 사전에 분류된 레코드들로 이루어진
훈련용 집합(training set)
 - 모든 사례에 대하여 목표변수 값을 알고 있음
- 목표
 - 입력변수 값에 기초하여 새로운 레코드의 목표
필드 값에 클래스를 할당할 수 있는
의사결정나무를 생성하는 것

훈련용 데이터의 예

- 캠페인 응답여부에 대한 의사결정나무 생성을 위한 고객 시그니처

입력 변수

목표 변수




	ID	AGE	INCOME	SEX	MARRIED	FICO	OWNHOME	LOC	CLIMATE	BUY6	BUY12	BUY18	VALUE24	RESPOND
1	001371057	71....	67.000	M	1.000	719....	0.000	A	10	1.000	1.000	1.000	318.000	0.000
2	002093270	53....	72.000	M	1.000	751....	0.000	A	10	0.000	0.000	0.000	83.000	0.000
3	002783726	53....	70.000	F	1.000	725....	0.000	A	10	1.000	1.000	1.000	265.000	0.000
4	010800860	45....	56.000	F	0.000	684....	0.000	A	10	0.000	0.000	1.000	448.000	0.000
5	014577797	32....	66.000	F	0.000	651....	0.000	A	10	0.000	0.000	0.000	161.000	0.000
6	015884859	35....	48.000	F	0.000	691....	1.000	A	10	0.000	0.000	0.000	250.000	0.000
7	017131376	43....	49.000	F	0.000	694....	1.000	A	10	0.000	0.000	0.000	194.000	0.000
8	018674857	39....	64.000	M	0.000	659....	0.000	A	10	0.000	0.000	0.000	446.000	0.000
9	019417226	66....	65.000	M	0.000	692....	0.000	A	10	0.000	0.000	0.000	214.000	0.000
10	021786286	\$n....	\$null\$		\$null\$	707....	\$null\$	A	10	0.000	0.000	0.000	198.000	0.000
11	026897464	52....	58.000	M	1.000	705....	1.000	A	10	0.000	1.000	2.000	216.000	0.000
12	028908796	29....	40.000	F	0.000	693....	0.000	A	10	0.000	0.000	0.000	118.000	0.000
13	031053878	48....	57.000	F	0.000	698....	0.000	A	10	0.000	0.000	0.000	226.000	0.000
14	032620343	67....	33.000	M	0.000	713....	0.000	A	10	0.000	0.000	0.000	145.000	1.000
15	033161772	44....	17.000	M	1.000	751....	0.000	A	10	1.000	1.000	1.000	494.000	0.000
16	034909540	59....	40.000	F	1.000	703....	0.000	A	10	0.000	0.000	1.000	485.000	1.000
17	037618388	47....	71.000	M	1.000	680....	0.000	A	10	0.000	0.000	0.000	258.000	0.000
18	042722465	49....	25.000	F	1.000	705....	1.000	A	10	0.000	0.000	0.000	230.000	0.000
19	043443115	36....	51.000	M	0.000	610....	0.000	A	10	0.000	0.000	0.000	189.000	0.000
20	051748064	23....	52.000	F	1.000	670....	0.000	A	10	0.000	0.000	0.000	412.000	0.000
21	055734274	58....	38.000	M	1.000	686....	0.000	A	10	1.000	1.000	1.000	499.000	1.000
22	055789810	50....	56.000	M	1.000	733....	0.000	A	10	0.000	0.000	0.000	107.000	0.000
23	055850946	39....	54.000	M	0.000	691....	0.000	A	10	0.000	1.000	1.000	228.000	0.000
24	059289533	63....	29.000	M	1.000	714....	0.000	A	10	0.000	0.000	0.000	162.000	0.000
25	059972696	47....	63.000	M	1.000	732....	0.000	A	10	0.000	0.000	0.000	97.000	0.000
26	060310775	55....	51.000	F	1.000	706....	0.000	A	10	0.000	0.000	1.000	283.000	0.000
27	060607990	45....	61.000	M	0.000	635....	0.000	A	10	0.000	0.000	1.000	337.000	0.000
28	066519221	49....	19.000	F	1.000	687....	0.000	A	10	0.000	0.000	1.000	349.000	0.000
29	066565950	48....	66.000	F	0.000	654....	0.000	A	10	1.000	1.000	2.000	180.000	0.000
30	066715668	54....	35.000	F	1.000	720....	0.000	A	10	0.000	0.000	0.000	76.000	0.000
31	069934651	42....	31.000	F	0.000	688....	0.000	A	10	0.000	0.000	0.000	162.000	0.000
32	071772074	46....	20.000	M	1.000	646....	0.000	A	10	0.000	0.000	0.000	256.000	0.000


분기의 발견

- 각 노드에서 분기
 - 단일 입력 필드의 함수
 - 최선의 분기를 제공하는 입력 변수를 선택하는 것
 - 순수도(purity)
 - 잠재적 분기를 평가하는 척도
- 순환적 알고리즘(recursive algorithm)
- Gini, 정보이익(information gain), 카이제곱
- F-테스트



좋은 분할은 모든 자식노드의 순수도를 증가시킨다






Original Data



Poor Split



Poor Split



Good Split

수치형 입력변수를 기반으로 분할하기

- 수치형 입력변수에서 이진 분할을 찾을 때,
- 훈련 집합 내의 변수가 가지는 모든 값은 분기의 후보값
 - $X < N, X \geq N$
- 효율성을 위해서, 어떤 분할 알고리즘은 실제로 모든 값들을 평가하는 대신에 값들의 표본을 평가하도록 구현되어 있음

범주형 입력변수를 기반으로 분할하기

- 가장 단순한 방법은 범주형 변수를 가지는 클래스별로 하나의 가지를 만드는 것
 - 예) 빨강, 주황, 노랑, 초록, 파랑, 남색, 보라
 - 종종 부실한 결과
- 좀더 일반적으로 사용되는 방법은 각기 유사한 결과를 예측하는 클래스들을 하나의 집단으로 묶는 것
 - 카이제곱 검정

결측값이 존재하는 경우의 분할

- 의사결정나무의 좋은 특징 중의 하나가 결측값을 다룰 수 있는 능력
 - 널 값을 하나의 가능한 가지로 다룸
- 많은 경우, 특정 값이 결측되었다는 것은 예측력을 가짐
 - 예) 가구 수준의 인구통계학적 데이터 내의 비결측값의 수가 정기 생명 보험 제안에 대한 응답률과 양의 상관관계를 보임

최대 나무(Full Tree)의 생성



- 분할 시도의 중단
 - 주어진 노드의 **순수도**를 유의한 수준으로 증가시키는 분할이 없을 때
 - 해당 노드에 속한 **레코드의 수**가 미리 설정한 하한선에 도달했을 때
 - 나무의 **깊이**가 미리 정해 놓은 한계에 도달했을 때
- **최대나무(Full tree)**는 일반적으로 새로운 레코드들의 집합을 분류하는 데 최상의 성과를 제공하는 나무는 아님

의사결정나무의 효과에 대한 측정

- 테스트 집합(test set)에 적용시켜 정확히 분류된 비율을 관찰
- 오차 비율(error rate)
 - 오분류율(Misclassification rate)
- 말단 노드인지, 중간 노드인지 상관없이, 각 노드에서 다음을 측정할 수 있음
 - 노드에 들어오는 레코드의 수
 - 각 클래스 내의 레코드의 비율
 - 말단노드라면 어떻게 분류되는지에 대한 정보
 - 노드에서 정확히 분류된 레코드의 비율
 - 훈련 집합과 테스트 집합 간의 분포에 대한 분산

데이터 집합을 분할

- 훈련용 데이터 집합: 모형 생성에 사용
- 검증용 데이터 집합: 모형 최적화에 사용
- 테스트 데이터 집합: 모형 성능 평가에 사용
- 3개의 데이터 집합은 disjoint 해야 함



3. 순수도 척도 – Gini와 엔트로피


최고의 분할을 선택하기 위한 테스트

- 잠재적 분할을 평가하기 위해 몇 가지 다른 척도들이 사용 가능
 - 대안적인 분할 기준들은 서로 다르게 보이면서도 비슷한 성능을 보이는 나무들을 결과로 나타냄

순수도와 다양성

- 분할의 결과는 순수도의 증가(increase in purity)
 - 다양성의 감소(decrease in diversity)
- 순수도 척도는 0(표본에 있는 두 항목이 모두 다른 클래스일 때)에서 1(모든 항목이 동일한 클래스 일 때)까지의 범위를 가짐
 - 이 값을 1에서 빼면 다양성 척도

이진 변수에 대한 좋은 분할은 순수도를 증가시킨다



〈그림 6-5〉 이진 변수에 대한 좋은 분할은 순수도를 증가시킨다.

순수도 척도

- 범주형 변수에 대한 분할을 평가하는 순수도 척도
 - 지니(Gini)
 - 엔트로피(Entropy, 정보 이익(information gain))
 - 정보 이익 비율(Information gain ratio)
 - 카이제곱 검정(Chi-square test)
- 수치형 목표 변수의 경우
 - 분산의 감소(reduction in variance)
 - F 검정

지니(모집단 다양성)

- 코라도 지니(Gini)
 - 이탈리아의 통계학자이자 경제학자
- 인구 다양성을 조사하는 생물학자들과 환경 공학자들이 자주 사용
- 같은 모집단에서 무작위로 선택된 두 항목들이 같은 클래스에 있을 확률
- 순수 모집단에 대하여 1

지니(모집단 다양성)

- Gini 척도
 - 클래스의 비율의 제곱의 합
 - $0.5*0.5 + 0.5*0.5 = 0.5$
 - $0.1*0.1+0.9*0.9 = 0.82$
 - $0.5 \sim 1.0$
- 때로, 점수에 2를 곱해서 1을 뺀
 - 0과 1 사이고
- 예제의 지니 점수
 - $(10/20)*0.82+(10/20)*0.82 = 0.82$

엔트로피 감소(정보 이익)

- 정보이론(Information theory)
 - 엔트로피(Entropy)
 - 시스템이 얼마나 정리되지 않았는지에 대한 척도
- 비트 수(number of bits)는 특정한 상황이나 결과를 설명하는 필요한 비트의 수
 - 시스템의 상태를 결정하기 위해 필요한 예/아니오 질문들
 - 예) 16가지 가능한 상태들이 있다면 $\log_2(16)$

엔트로피 감소(정보 이익)

- 특정 의사결정나무 노드의 엔트로피(entropy)
 - 노드에서 포함된 모든 클래스에 대하여, 특정 클래스의 레코드의 비율을 구하고, 이 값과 이 값에 밑이 2인 로그를 취한 값을 곱한 값들의 합(주로 양수를 만들기 위해서 -1을 곱함)
 - $-1 * (P(\text{검은점})\log_2 P(\text{검은점}) + p(\text{흰점})\log_2 P(\text{흰점}))$

엔트로피 감소(정보 이익)

- $-1*(0.5* \log_2(0.5) + 0.5* \log_2(0.5)) = +1$
- $\text{Entropy}_{\text{left}} = -1*(0.1* \log_2(0.1) + 0.9* \log_2(0.9)) = 0.33 + 0.14 = 0.47$
- 분기의 엔트로피 = $(0.5)* \text{Entropy}_{\text{left}} + (0.5)* \text{Entropy}_{\text{right}} = 0.5*0.47 + 0.5*0.47 = 0.47$
- 정보이익 = $1 - 0.47 = 0.53$

4. 순수도 척도 – Information Gain Ratio와 카이제곱, 연속형 목표변수의 순수도 척도

정보 이익 비율

- 엔트로피 분할 척도는 각각의 값에 대한 별개의 가치를 치는 범주형 입력변수들에 관한 분할 방법과 결합되었을 때 문제를 발생 시킴
 - 호주의 학자 Quilan의 ID3
- 단순히 가지의 수가 늘어남에 따라서 엔트로피가 감소하는 것을 분할의 내재 정보(intrinsic information) 라고 함
 - 예) 무작위의 n 개 분할의 경우, -1^*
 $((1/n) \cdot \log_2(1/n) + \dots + (1/n) \cdot \log_2(1/n)) = -\log_2(1/n)$

정보 이익 비율

- Bushy trees

- 다중 분할에서의 내재 정보 때문에, 분할로 인한 내재 정보를 교정하지 않고 엔트로피 감소만을 분할 기준으로 사용하여 생성한 의사결정나무는 가지가 많아지는 경향이 있음
- 분할의 총 정보 이익과 가지의 숫자로 계산

카이제곱 검정

- Chi-square(χ^2) 검정
 - 통계학적 유의성에 대한 검정
 - 1900년에 영국의 통계학자 칼 피어슨(Karl Pearson)이 개발
 - 빈도에 대한 기대값과 관측값의 표준화된 차이의 제곱들의 합으로 정의
 - 관측된 표본들 간의 차이가 우연에 의한 것일 확률을 측정

카이제곱 검정

- $r \times c$ contingency table

입력\목표	Cat_1	Cat_2	...	Cat_c	Total
Cat_1	f11	f12		f1c	f1.
Cat_2	f21	f22		f2c	f2.
					
Cat_r	fr1	fr2		frc	fr.
Total	f.1	f.2		f.c	f..

- Pearson's Chi-square(χ^2) statistic

- $\chi^2 = \sum_{i,j} (f_{ij} - e_{ij})^2 / e_{ij}$

- f_{ij} : (i,j)셀의 관측 빈도

- e_{ij} : (i,j)셀의 예측 빈도

- $e_{ij} = (f_{i.} * f_{.j}) / f_{..}$

- 자유도 $(r-1)(c-1)$ 의 카이제곱 분포를 따름

카이제곱 검정

	성공	실패	합
남성	40	20	60
여성	10	30	40
합계	50	50	100

$$f_{11} = 40, f_{12}=20, f_{21}=10, f_{22}=3$$

$$E_{11} = (f_{1.} * f_{.1}) / f_{..} = (60 * 50) / 100 = 30$$

$$E_{12} = (f_{1.} * f_{.2}) / f_{..} = (60 * 50) / 100 = 30$$

$$E_{21} = (f_{2.} * f_{.1}) / f_{..} = (40 * 50) / 100 = 20$$

$$E_{22} = (f_{2.} * f_{.2}) / f_{..} = (40 * 60) / 100 = 20$$

$$\chi^2 = (40-30)^2/30 + (20-30)^2/30 + (10-20)^2/20 + (30-20)^2/20 = 100/6$$

카이제곱 검정

- **CHAID** (Chi-squared Automatic Interaction Detection)
 - 1975년 John A. Hartigan에 의해서 발표
 - 원래 개발 동기는 변수들 간의 통계적 관계를 감지하는 것
- CHAID에서는 카이제곱 검정을 다양하게 사용
 - 목표변수에 대한 유의하게 다른 효과를 가지지 않은 클래스들을 통합할 때
 - 최선의 분할을 고를 때
 - 노드에 대하여 추가적인 분할이 필요한 지를 결정할 때


카이제곱 검정

- CHAID

- 고전적인 CHAID 알고리즘에서는 모든 입력변수는 범주형(categorical)이어야 함
 - 연속형 변수들은 구간화(binning)하거나 대, 중, 소와 같은 순차적인 클래스로 대체되어야 함
- SAS Enterprise Miner
 - 범주형의 경우는 카이제곱 검정 사용
 - 연속형 변수에는 F-검정 사용

분산의 감소

- 목표변수가 수치형(numeric) 일 때, 좋은 분할은 목표변수의 분산을 줄임
- 분산은 각 값의 평균과의 차이를 제곱한 값의 평균
 - $\text{Variance} = \sum_i (X_i - \mu)^2 / N$
 - 예) 검은 점을 1, 흰 점을 0이라 하면
 - 부모 노드의 분산 = $20 \times 0.5^2 / 20 = 0.25$
 - 자식 노드의 분산 = $(0.9^2 + 9 \times 0.1^2) / 10 = 0.09$



(그림 6-5) 이진 변수에 대한 좋은 분할은 순수도를 증가시킨다.

F검정

- 수치형 목표변수에 대한 또 다른 검정 기준
- 영국의 통계학자, 천문학자, 유전학자 Ronald A. Fisher의 이름을 따
- Fisher's test
 - 연속형 변수에는 F 검정 vs. 범주형 변수에는 카이제곱 검정
 - 다른 평균과 분산을 가진 표본들이 같은 모집단에서 실제로 나왔을 확률에 대한 척도 제공
- F 점수
 - 두 추정치의 비율
 - 한 추정치는 모든 표본을 포함하는 집단에서 합쳐진 분산으로부터 유도, 다른 하나는 표본 평균들로 계산된 표본들 사이의 분산으로 유도
 - 점수가 클 수록 표본들이 같은 모집단에서 나왔을 확률이 높음